

Data Cleaning dengan Pandas

Data Science — Kelas XII RPL — Semester Ganjil

Kurikulum Merdeka · Tahun Pelajaran 2026/2027

A. Identitas Pembelajaran

Komponen	Keterangan
Mata Pelajaran	Data Science
Kelas / Fase	XII RPL / Fase F
Semester	Ganjil
Alokasi Waktu	8 JP (1 pertemuan)
Topik	Data Cleaning dengan Pandas (missing value, duplikasi, dan tipe data)
Kaitan Materi Sebelumnya	Melanjutkan materi Eksplorasi & Seleksi Data dengan Pandas (loc/iloc, filtering, sorting) — data yang sudah bisa diseleksi kini akan dibersihkan sebelum dianalisis lebih lanjut
Kaitan Materi Selanjutnya	Agregasi & Pengelompokan Data dengan groupby()
Tools	Google Colab (Python 3, library Pandas sudah tersedia otomatis)
Dataset Praktik	dataset_ekstrakurikuler_siswa.csv (505 baris, data pendaftaran ekstrakurikuler — lihat Bagian E)

B. Tujuan Pembelajaran

- 1 Peserta didik mampu mendeteksi dan menangani missing value (data hilang/NaN) pada DataFrame menggunakan `isna()`, `dropna()`, dan `fillna()`.
- 2 Peserta didik mampu mendeteksi dan menghapus baris data duplikat menggunakan `duplicated()` dan `drop_duplicates()`.
- 3 Peserta didik mampu memeriksa dan mengonversi tipe data kolom yang tidak sesuai menggunakan `astype()`, `pd.to_numeric()`, dan `pd.to_datetime()`.

C. Apersepsi / Pemantik

Sebelum masuk ke materi inti, ajak peserta didik mengingat kembali materi sebelumnya: mereka sudah bisa menyaring dan mengurutkan data menggunakan `loc/iloc`, boolean indexing, dan `sort_values`. Namun, tanyakan: "Bagaimana jika data yang difilter ternyata ada yang kosong (NaN), ada baris yang tercatat dua kali karena double-input, atau kolom tanggal masih berbentuk teks?" Sampaikan bahwa inilah alasan data scientist di industri sering menyebut tahap ini sebagai tahap paling menyita waktu.

Fakta Industri

Berbagai laporan praktisi data science menyebutkan bahwa data scientist menghabiskan sekitar 60–80% waktu kerjanya untuk membersihkan dan menyiapkan data, dan hanya sisanya untuk analisis maupun pemodelan sesungguhnya. Prinsip lama di dunia industri, *"garbage in, garbage out"*, berlaku persis di sini: model atau laporan yang dibangun dari data kotor akan menghasilkan kesimpulan yang meyakinkan tapi salah.

D. Materi Inti

D.1 Mendeteksi dan Menangani Missing Value

Data di dunia nyata jarang sekali lengkap 100%. Sensor yang gagal merekam, responden survei yang tidak menjawab semua pertanyaan, atau sistem lama yang tidak mewajibkan pengisian kolom tertentu, semuanya bisa menghasilkan data kosong. Dalam Pandas, data kosong direpresentasikan sebagai **NaN** (Not a Number).

a. Mendeteksi missing value

Gunakan **isna()** (atau **isnull()**, keduanya identik) untuk memeriksa sel mana yang kosong.

```
import pandas as pd

df = pd.DataFrame({
    'nama': ['Andi', 'Bela', 'Citra', 'Dedi'],
    'nilai': [85, None, 90, None],
    'kota': ['Bandung', 'Jakarta', None, 'Bandung']
})

print(df.isna())          # True/False per sel
print(df.isna().sum())    # jumlah NaN per kolom
```

Perintah **df.isna().sum()** adalah kebiasaan wajib setiap kali membuka dataset baru di dunia kerja: sebelum menganalisis apa pun, cek dulu kolom mana yang paling banyak datanya hilang.

b. Menghapus baris/kolom dengan missing value — **dropna()**

```
df.dropna()                # hapus baris yang punya minimal 1 NaN
df.dropna(subset=['nilai']) # hapus baris hanya jika kolom 'nilai' kosong
df.dropna(axis=1)          # hapus kolom yang punya NaN
df.dropna(thresh=2)        # pertahankan baris jika minimal 2 kolom terisi
```

Gunakan **dropna()** hanya jika baris yang hilang jumlahnya sedikit dan menghapusnya tidak akan mengubah kesimpulan analisis secara signifikan. Jika satu kolom penting hilang di banyak baris, menghapus semuanya justru membuang informasi berharga.

c. Mengisi missing value — **fillna()**

```
df['nilai'].fillna(0, inplace=True)          # isi dengan nilai tetap
df['nilai'].fillna(df['nilai'].mean(), inplace=True) # isi dengan rata-rata
df['kota'].fillna('Tidak Diketahui', inplace=True) # isi data kategorikal
df['nilai'].fillna(method='ffill', inplace=True)  # isi dari nilai sebelumnya
```

Studi Kasus: Rekap Absensi Karyawan Startup

Bagian HR sebuah startup memiliki data absensi 200 karyawan dari mesin fingerprint. Karena gangguan jaringan di beberapa hari, kolom **jam_masuk** memiliki 15 data kosong. Tim data memutuskan: kolom **jam_masuk** yang kosong diisi dengan jam rata-rata masuk karyawan tersebut (bukan dihapus), karena menghapus 15 baris berarti kehilangan seluruh rekap kehadiran karyawan itu di hari tersebut — padahal informasi kehadirannya (hadir/tidak) tetap valid dan dibutuhkan untuk perhitungan tunjangan.

D.2 Mendeteksi dan Menghapus Data Duplikat

Duplikasi data sering terjadi karena input ganda (misalnya pelanggan mengisi formulir dua kali) atau proses penggabungan data dari beberapa sumber yang tumpang tindih.

```
df.duplicated()                # True jika baris sama persis dengan
baris sebelumnya
df.duplicated().sum()          # jumlah baris duplikat
df.duplicated(subset=['nama']) # anggap duplikat jika kolom 'nama' sama

df.drop_duplicates(inplace=True) # hapus duplikat, simpan
kemunculan pertama
df.drop_duplicates(subset=['nama'], keep='last', inplace=True) # simpan
kemunculan terakhir
```

Parameter **keep** menentukan baris mana yang dipertahankan: **'first'** (default, ambil data paling awal), **'last'** (ambil data paling baru — cocok jika data terakhir dianggap paling akurat, misalnya hasil update terbaru), atau **False** (hapus semua baris yang punya kembar, tidak menyisakan satupun).

D.3 Memeriksa dan Mengonversi Tipe Data

Masalah umum lain: data numerik yang ter-input sebagai teks (string), atau tanggal yang masih berupa teks biasa sehingga tidak bisa diurutkan atau dihitung selisih harinya.

```
df.dtypes          # cek tipe data tiap kolom

df['harga'] = df['harga'].astype(float)          # konversi langsung ke float
df['stok'] = pd.to_numeric(df['stok'], errors='coerce') # konversi ke angka, gagal -> NaN
df['tanggal'] = pd.to_datetime(df['tanggal'], format='%d-%m-%Y') # konversi ke tipe tanggal
```

Perbedaan **astype()** dan **pd.to_numeric()**: **astype()** akan langsung error jika ada satu saja data yang tidak bisa dikonversi (misalnya teks "tidak diisi" di kolom angka), sedangkan **to_numeric()** dengan **errors='coerce'** akan mengubah data bermasalah tersebut menjadi NaN tanpa menghentikan program — sehingga data itu bisa dideteksi dan ditangani belakangan dengan **isna()**.

Studi Kasus: Data Penjualan E-Commerce

Tim analitik sebuah toko online mengunduh data transaksi dari tiga marketplace berbeda lalu menggabungkannya menjadi satu file. Setelah digabung, ditemukan: (1) 40 transaksi tercatat dua kali karena proses penggabungan, (2) kolom harga bercampur format "25000" dan "Rp25.000" sehingga terbaca sebagai teks, dan (3) kolom tanggal_transaksi berformat berbeda-beda antar marketplace. Ketiga masalah ini harus diselesaikan satu per satu — **drop_duplicates()** untuk transaksi ganda, pembersihan teks lalu **to_numeric()** untuk kolom harga, dan **to_datetime()** dengan format yang disesuaikan untuk kolom tanggal — sebelum data ini layak dipakai menghitung total pendapatan harian.

D.4 Alur Kerja Data Cleaning yang Disarankan

Di dunia kerja, pembersihan data biasanya dilakukan sebagai checklist berurutan, bukan asal-asalan:

- 1 Cek ukuran & struktur data: **df.shape**, **df.info()**, **df.dtypes**.
- 2 Cek missing value: **df.isna().sum()** — putuskan mana yang di-drop, mana yang diisi.
- 3 Cek duplikasi: **df.duplicated().sum()** — hapus dengan **drop_duplicates()**.
- 4 Cek & perbaiki tipe data: pastikan kolom angka bertipe angka, kolom tanggal bertipe **datetime**.
- 5 Cek konsistensi nilai kategorikal: **df['kolom'].unique()** — apakah ada variasi penulisan seperti "Pria"/"pria"/"L" untuk data yang sama.

E. Studi Kasus Utama: Data Pendaftaran Ekstrakurikuler Siswa

Untuk praktik dan asesmen pada pertemuan ini, digunakan satu dataset nyata bergaya sekolah: rekap **pendaftaran ekstrakurikuler siswa** (berkas **dataset_ekstrakurikuler_siswa.csv**, 505 baris, 12 kolom). Dataset ini sengaja dibuat "kotor" — bukan karena human error semata, tetapi untuk mensimulasikan kondisi nyata data hasil rekap manual panitia ekstrakurikuler dari beberapa sumber (formulir kertas, WhatsApp wali kelas, dan input ulang panitia).

Kolom	Keterangan
id_pendaftaran	Kode unik pendaftaran, format EKS2026XXXX
nama_siswa, kelas	Identitas siswa yang mendaftar
jenis_kelamin	Berisi campuran 'L'/'P' dan 'Laki-laki'/'Perempuan' (kapitalisasi tidak konsisten)
ekstrakurikuler, pembina	Nama ekstrakurikuler yang diikuti beserta pembinanya
tanggal_daftar	Tanggal pendaftaran — format bercampur: dd/mm/yyyy, yyyy-mm-dd, dan dd-mm-yyyy
no_hp_orangtua	Nomor HP orang tua/wali; sebagian kosong
nilai_rata_rata	Nilai rata-rata rapor siswa; ada yang pakai koma ("85,5"), titik ("85.5"), teks "belum dinilai", atau kosong
kehadiran_persen	Persentase kehadiran; sebagian pakai simbol % ("90%"), sebagian angka polos, sebagian kosong
status_pembayaran	Status iuran ekstrakurikuler; campuran 'Lunas'/'lunas'/'LUNAS'/'Belum Lunas'/'belum lunas', sebagian kosong
catatan	Catatan tambahan panitia; sebagian besar memang kosong (wajar, bukan error)

Masalah yang Perlu Ditemukan Sendiri oleh Peserta Didik

Dataset ini mengandung: (1) missing value di kolom `no_hp_orangtua`, `nilai_rata_rata`, `kehadiran_persen`, dan `status_pembayaran`; (2) 15 baris duplikat persis (double-input); (3) 25 `id_pendaftaran` yang muncul lebih dari sekali dengan nilai kolom lain berbeda (kasus data ter-update); (4) kolom `nilai_rata_rata` dan `kehadiran_persen` bertipe teks karena format campur; (5) kolom `tanggal_daftar` dengan tiga format berbeda; dan (6) kolom `jenis_kelamin` serta `status_pembayaran` dengan variasi penulisan kategori yang sama. Guru tidak perlu memberi tahu di awal — biarkan peserta didik menemukannya lewat eksplorasi `info()`, `isna().sum()`, `duplicated().sum()`, dan `unique()`.

F. Aktivitas Praktik (Kerja Kelompok)

Peserta didik bekerja dalam kelompok kecil (3–4 orang) menggunakan dataset_ekstrakurikuler_siswa.csv yang sama. Setiap kelompok membersihkan dataset secara bertahap dan mendokumentasikan keputusannya.

- 1 Muat dataset_ekstrakurikuler_siswa.csv ke Google Colab. Tampilkan `df.shape`, `df.info()`, dan `df.isna().sum()` untuk memetakan masalah pada tiap kolom.
- 2 Tangani missing value: putuskan apakah `no_hp_orangtua`, `nilai_rata_rata`, `kehadiran_persen`, dan `status_pembayaran` sebaiknya di-drop atau diisi (dan diisi dengan nilai apa) — berikan alasannya.
- 3 Deteksi dan hapus baris duplikat persis dengan `drop_duplicates()`. Kemudian deteksi `id_pendaftaran` yang muncul lebih dari sekali dan tentukan strategi (misalnya `keep='last'` karena dianggap data ter-update).
- 4 Bersihkan kolom `nilai_rata_rata` (satukan format koma/titik menjadi angka desimal) dan `kehadiran_persen` (hilangkan simbol % lalu konversi ke angka) menggunakan kombinasi `str.replace()` dan `pd.to_numeric()`.
- 5 Konversi kolom `tanggal_daftar` yang berformat campur menjadi satu tipe `datetime` yang konsisten.
- 6 Rapikan kategori pada kolom `jenis_kelamin` (jadikan hanya 'L'/'P') dan `status_pembayaran` (jadikan hanya 'Lunas'/'Belum Lunas') menggunakan `df['kolom'].unique()` untuk memeriksa lalu `str.strip()/str.lower()/mapping manual`.
- 7 Simpan hasil akhir ke file baru, misalnya `dataset_ekstrakurikuler_bersih.csv`, lalu laporkan jumlah baris sebelum vs sesudah dibersihkan.

Catatan untuk Guru

Sengaja tekankan bahwa tidak ada satu jawaban "benar" tunggal dalam data cleaning — keputusan drop vs fill selalu bergantung pada konteks. Dorong tiap kelompok mempertahankan alasan pilihannya saat presentasi singkat, bukan sekadar menjalankan kode. Dataset ini juga akan dipakai kembali pada materi `groupby()` berikutnya, jadi hasil pembersihan kelompok sebaiknya disimpan.

G. Asesmen Formatif (Individu)

Masih menggunakan dataset_ekstrakurikuler_siswa.csv yang sama, kerjakan secara individu (boleh melanjutkan hasil kerja kelompok sebagai titik awal, namun jawaban dan interpretasi ditulis sendiri):

- 1 Tampilkan jumlah missing value pada setiap kolom sebelum dibersihkan, dan jelaskan kolom mana yang menurutmu paling aman untuk di-drop, serta kolom mana yang lebih baik diisi (`fillna`) — sertakan alasan.
- 2 Hapus seluruh baris yang duplikat persis, lalu tangani `id_pendaftaran` yang duplikat dengan `keep='last'`. Laporkan berapa baris yang berkurang pada masing-masing langkah.
- 3 Bersihkan dan konversi kolom `nilai_rata_rata` serta `kehadiran_persen` menjadi tipe numerik yang konsisten (satu satuan, satu format desimal).

- 4 Tampilkan `df['jenis_kelamin'].unique()` dan `df['status_pembayaran'].unique()` sebelum dan sesudah dirapikan, untuk membuktikan bahwa jumlah kategori berkurang menjadi hanya kategori yang valid.
- 5 Setelah data bersih, hitung rata-rata sederhana dari kolom `nilai_rata_rata` menggunakan `.mean()` — bandingkan hasilnya sebelum dan sesudah kolom tersebut dibersihkan tipenya, lalu jelaskan mengapa hasilnya bisa berbeda (atau kenapa sebelum dibersihkan perhitungan ini malah tidak bisa dilakukan sama sekali).

H. Rangkuman & Tindak Lanjut

- Missing value (NaN) dideteksi dengan `isna()`, ditangani dengan `dropna()` (hapus) atau `fillna()` (isi).
- Data duplikat dideteksi dengan `duplicated()` dan dihapus dengan `drop_duplicates()`, dengan parameter `keep` untuk menentukan data mana yang dipertahankan.
- Tipe data yang salah dikonversi dengan `astype()`, `pd.to_numeric()`, atau `pd.to_datetime()`; `errors='coerce'` membantu menangani data yang gagal dikonversi tanpa menghentikan program.
- Data cleaning idealnya dilakukan sebagai alur kerja berurutan: cek struktur → missing value → duplikasi → tipe data → konsistensi kategori.

Tindak lanjut: pada materi selanjutnya, dataset `ekstrakurikuler_siswa.csv` yang sudah bersih ini akan diolah lebih lanjut menggunakan **`groupby()`** untuk melakukan agregasi dan pengelompokan data — misalnya menghitung rata-rata nilai atau tingkat kehadiran per ekstrakurikuler, atau jumlah pendaftar per kelas.

I. Glosarium

Missing value — Nilai yang tidak tersedia/kosong pada suatu sel data, direpresentasikan sebagai NaN di Pandas.

NaN — Singkatan dari Not a Number; simbol standar Pandas/NumPy untuk data yang hilang.

Duplikasi data — Kondisi ketika satu atau lebih baris data memiliki nilai yang identik dengan baris lain.

Type casting / konversi tipe data — Proses mengubah tipe data suatu kolom, misalnya dari teks menjadi angka atau tanggal.

`errors='coerce'` — Parameter yang membuat proses konversi data tetap berjalan dengan mengubah data bermasalah menjadi NaN, bukan menghentikan program dengan error.

J. Referensi

- McKinney, W. *Python for Data Analysis*, edisi ke-3 — Bab Data Cleaning and Preparation.
- Dokumentasi resmi Pandas: pandas.pydata.org/docs — bagian Working with missing data.
- ProCogia. *Data Cleaning in Python: Pandas Tricks Every Analyst Should Know*.